1. Datos analizados

El código localizó automáticamente la hoja que contiene `total_neto`; de esta forma no depende de escribir manualmente el nombre de la hoja, que incluye acentos. Las 14 columnas originales incluyen datos de folio, fecha, artículo, marca, precio, unidades, importe neto, cliente, ubicación y vendedor.

Tabla 1: Resumen del conjunto de datos usado

Característica	**Resultado**
Libro	`Datos_Complementarios_CLV.xlsx`
Hoja seleccionada	`Histórico_Ventas`
Registros iniciales	21 632
Columnas iniciales	14
Periodo de documentos	05/01/2026–15/10/2026
Variable objetivo continua	`total_neto`
Variables numéricas predictoras	`precio_unitario`, `total_unidades`
Marca para clasificación logística	`marc`

1.1. Variables y significado

- `total_neto`: importe neto de la línea de venta. Es la variable objetivo de las regresiones lineales y la variable original de la que se deriva la clase logística.
- `precio_unitario`: precio por unidad. Se transforma con $\ln(1 + x)$ antes de entrenar los modelos.
- `total_unidades`: cantidad vendida. Se limita por IQR; el código no le aplica transformación logarítmica.
- `marc`: marca del artículo. En el modelo logístico se convierte en indicadores binarios mediante variables dummy.

Se excluyeron como predictores campos cuyos nombres contienen tokens de identificación: `folio_abreviado`, `folio`, `articulo_id`, `nombre_articulo` y `cp`. Los campos de texto distintos de `marc` no se incorporaron al modelo logístico. Esta decisión evita tratar códigos y nombres como magnitudes numéricas, pero también significa que cliente, estado, ciudad y vendedor no forman parte de los predictores evaluados.

2. Preprocesamiento

2.1. Valores faltantes

El único campo con valores faltantes fue `cp`: 492 de 21 632 registros, equivalentes a aproximadamente 2.27 % de las filas. Para columnas numéricas, el notebook sustituye los nulos con la mediana observada de la columna. Por lo tanto, el código completó esos códigos postales con la mediana observada, 54 190. No había valores faltantes en `total_neto`. Al terminar esta etapa quedaron cero celdas nulas en la tabla procesada.

Aunque el código completa `cp`, esta columna se excluye después de los modelos por tratarse de un código identificador/geográfico, no de una medida continua.

2.2. Outliers

Para cada columna numérica no identificadora, el notebook calcula el primer y tercer cuartil, Q_1 y Q_3, y el rango intercuartílico $IQR = Q_3 - Q_1$. Los límites se calculan como:

$$L_{\text{inferior}} = Q_1 - 1{,}5(IQR), \qquad L_{\text{superior}} = Q_3 + 1{,}5(IQR).$$

Los valores que quedan fuera de los límites no se eliminan: se recortan al límite más cercano con la función `clip`. La tabla siguiente indica cuántas observaciones fueron recortadas con los datos originales.

Tabla 2: Límites IQR aplicados a las variables numéricas

Variable	Q_1	Q_3	**Límite superior**	**Valores recortados**
`precio_unitario`	172.4138	1 284.4800	2 952.5793	1 076 (4.97 %)
`total_unidades`	1	2	3.5	3 659 (16.91 %)
`total_neto`	200	2 148.4975	5 071.2438	2 150 (9.94 %)

Los límites inferiores calculados fueron $-1\,495{,}6855$ para el precio, $-0{,}5$ para las unidades y $-2\,722{,}7463$ para el neto. Como los valores observados fueron no negativos, los valores extremos contados en estas tres variables excedían el límite superior.

Importante: `total_unidades` produce un máximo de 3.5 unidades, aunque la cantidad original es entera. Esto es una consecuencia de usar el mismo recorte IQR para toda variable numérica; conviene considerar redondear esa columna a enteros o justificar explícitamente esta decisión en la versión final del análisis.

2.3. Transformación

Después del recorte IQR, el sesgo de `precio_unitario` fue aproximadamente 1.155. Como es una variable no negativa y su sesgo absoluto superó 1, se transformó usando:

$$x_{\text{transformado}} = \ln(1 + x_{\text{original}}).$$

Esta transformación se aplicó solamente a `precio_unitario`; no se transformó `total_neto`, que se mantuvo como objetivo en escala de importe. Por ello, el predictor llamado `precio_unitario` en las ecuaciones de regresión representa $\ln(1 + \text{precio unitario original})$, no el precio original sin transformar.

2.4. Resumen antes y después

Antes del preprocesamiento, `total_neto` tenía media 5 388.64, mediana 948.28 y máximo 2 170 948.28. Su media fue 1 509.08 y su máximo quedó en 5 071.24. Esta reducción se debe al recorte de importes extremos, no a la eliminación de renglones. Se conservaron los 21 632 registros.

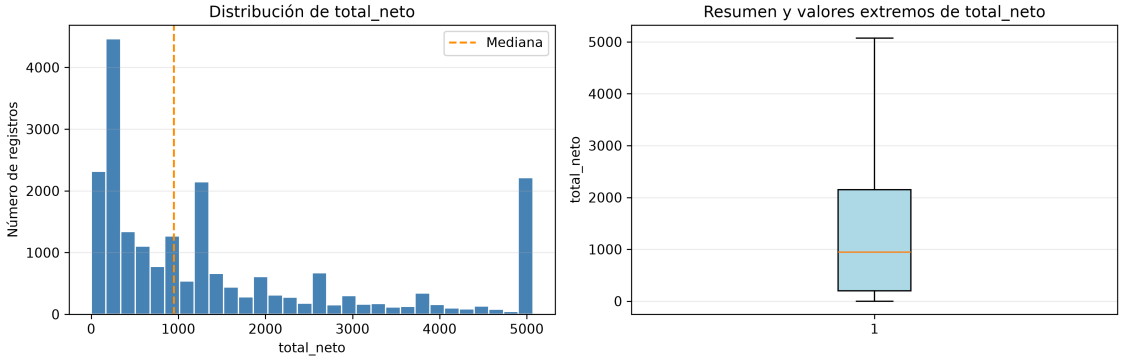


Figura 1: Distribución de `total_neto` después del preprocesamiento. Se espera ver el histograma, la mediana y el boxplot.



Figura 2: Diez marcas con mayor frecuencia en los renglones de venta.

3. Correlación

Se calculó la correlación de Pearson entre las variables numéricas seleccionadas. Pearson mide asociación lineal y toma valores entre -1 y 1. Un valor positivo indica que ambas variables tienden a aumentar juntas; uno negativo indica que una tiende a disminuir cuando la otra aumenta. La correlación no demuestra causalidad.

3.1. Matriz con los valores originales

La primera matriz se calcula con los datos del Excel antes de transformar variables:

	precio_unitario	total_unidades	total_neto
precio_unitario	1,0000	−0,0298	0,9927
total_unidades	−0,0298	1,0000	0,0096
total_neto	0,9927	0,0096	1,0000

3.2. Matriz después del preprocesamiento

	precio_unitario	total_unidades	total_neto
precio_unitario	1,0000	−0,0156	0,5577
total_unidades	−0,0156	1,0000	0,4562
total_neto	0,5577	0,4562	1,0000

En los datos originales, precio y neto muestran una correlación de 0.9927. Después de limitar valores extremos y transformar el precio, la correlación baja a 0.5577. Este cambio muestra que la relación original estaba muy influida por magnitudes extremas y por la escala de las variables. Después del preprocesamiento, unidades y neto presentan una correlación positiva moderada de 0.4562. Precio y unidades tienen una correlación cercana a cero, −0,0156.

El modelo lineal selecciona variables usando el conjunto de entrenamiento. En ese subconjunto, las correlaciones con el objetivo fueron 0.5572 para el precio transformado y 0.4641 para las unidades. Por eso el predictor de la regresión simple es el precio transformado.

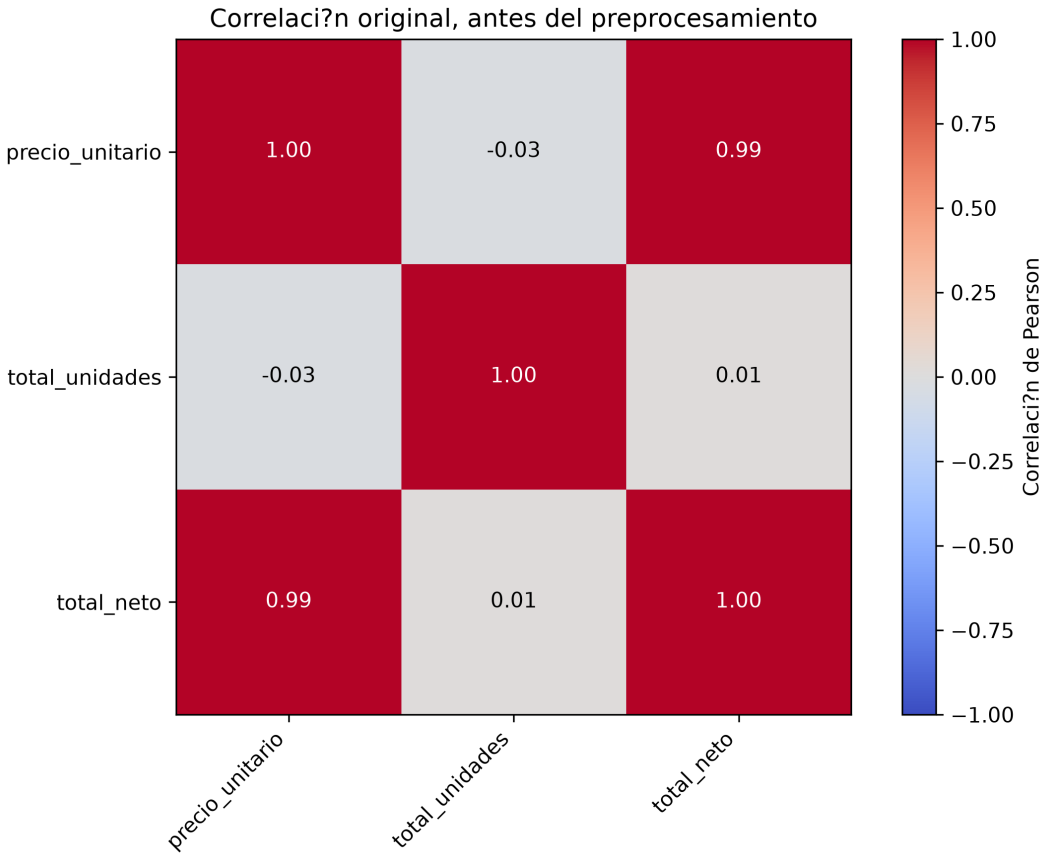


Figura 3: Mapa de calor de la matriz de Pearson calculada antes del preprocesamiento.

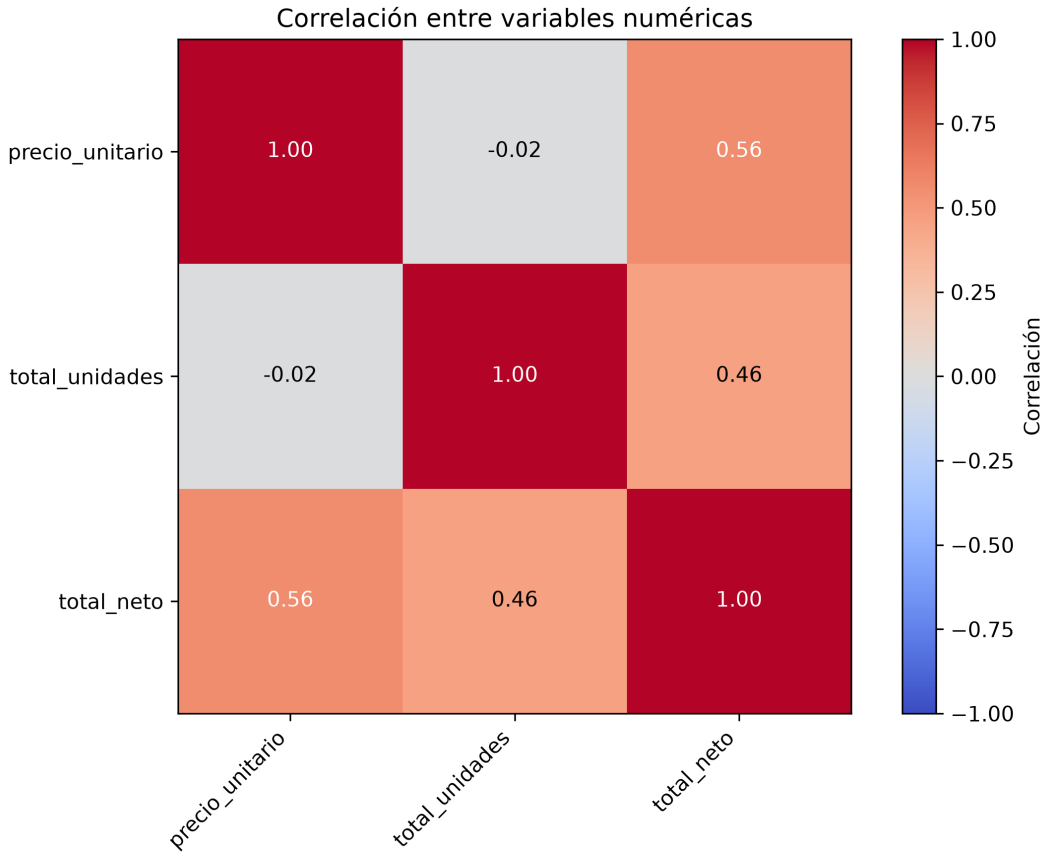


Figura 4: Mapa de calor de la matriz de Pearson calculada después de transformar.

4. Regresión lineal

4.1. Separación de entrenamiento y prueba

Los modelos lineales utilizan `train_test_split` con `test_size=0.2` y `random_state=42`. Se asignaron 17 305 filas a entrenamiento (80 %) y 4 327 filas a prueba (20 %). El modelo se ajusta en entrenamiento y sus métricas reportadas se calculan en prueba. La métrica R^2 expresa la proporción de variación del objetivo explicada por el modelo en la muestra evaluada; $R^2 = 1$ representa ajuste perfecto y $R^2 = 0$ no supera al predictor constante basado en la media, bajo la definición estándar.

4.2. Regresión lineal simple

Se calcularon en entrenamiento las correlaciones absolutas de cada predictor numérico con `total_neto`. El precio transformado tuvo la mayor correlación absoluta, $r = 0{,}5572$, y fue

seleccionado. El modelo es:

$$\widehat{\texttt{total_neto}} = -1\,123{,}980 + 453{,}499\,\ln(1 + \texttt{precio_unitario original}).$$

Tabla 3: Resultados de la regresión simple en el conjunto de prueba

Métrica	**Resultado**
Predictor	`precio_unitario` transformado
Correlación en entrenamiento	0.5572
Intercepto	$-1\,123{,}980$
Pendiente	453.499
R^2 de prueba	0.3131
MAE de prueba	1 107.417
RMSE de prueba	1 330.102

La pendiente positiva representa un aumento esperado de aproximadamente 453.499 unidades monetarias en el objetivo por cada unidad de aumento en el predictor transformado, bajo el modelo lineal. No representa el efecto de aumentar una unidad del precio original. El $R^2 = 0{,}3131$ indica que el modelo explica alrededor de 31.31 % de la variación observada en prueba. El MAE es el promedio del valor absoluto del error de predicción; el RMSE penaliza más fuertemente los errores grandes.

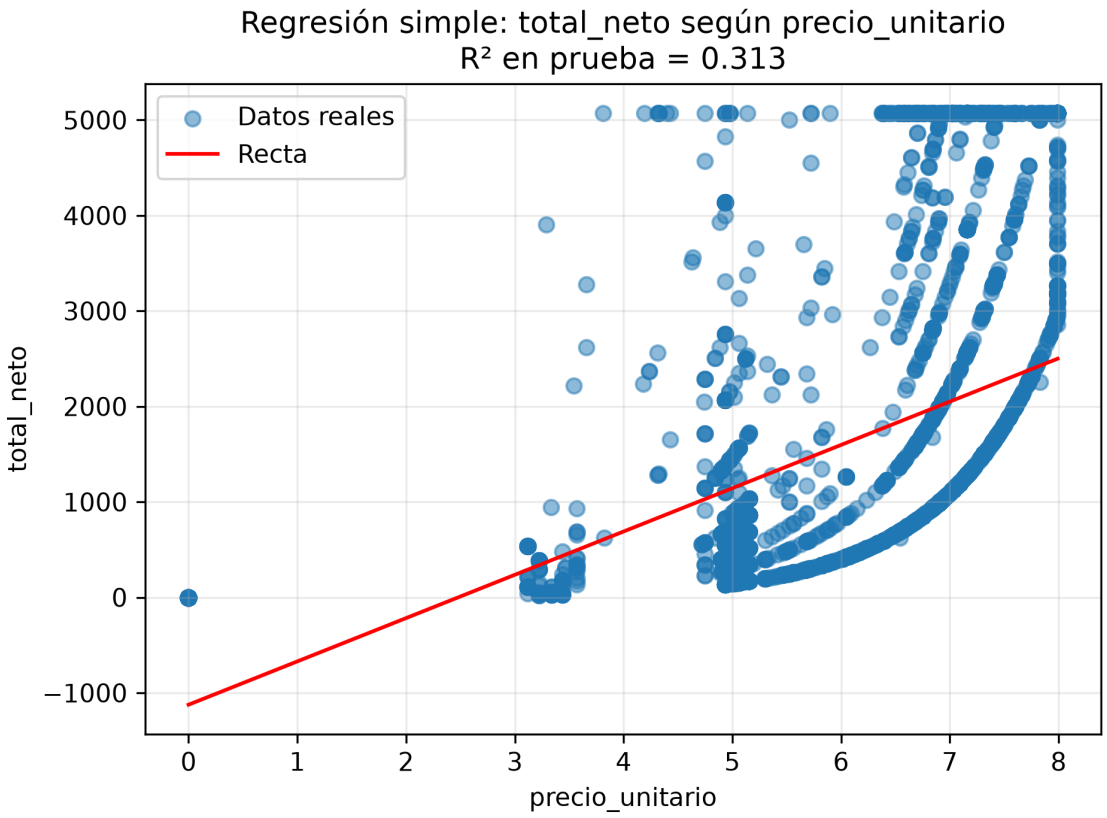


Figura 5: Regresión lineal simple

4.3. Regresión lineal múltiple

La lógica selecciona hasta tres predictores ordenados por correlación absoluta con el objetivo en entrenamiento. Después de excluir identificadores, solo quedaron dos predictores numéricos: el precio transformado y las unidades. Por ello, el modelo múltiple utilizó ambos:

$$\widehat{\texttt{total_neto}} = -2\,457{,}592 + 457{,}515\,\ln(1+\texttt{precio_unitario original}) + 763{,}230\,\texttt{total_unidades}.$$

Tabla 4: Resultados de la regresión múltiple en el conjunto de prueba

Métrica	**Resultado**
Predictores	Precio transformado
Intercepto	−2 457,592
Coeficiente de precio transformado	457.515
Coeficiente de unidades	763.230
R^2 de prueba	0.5102
MAE de prueba	870.258
RMSE de prueba	1 123.174

El coeficiente de precio en la regresión múltiple es 457.515, ligeramente mayor que la pendiente simple, 453.499. En el modelo múltiple dicho coeficiente se interpreta manteniendo constante la cantidad; la pendiente simple no controla por unidades. El coeficiente estimado para unidades es 763.230 por cada unidad adicional de la variable, manteniendo constante el precio transformado. Como se dejan valores de unidades hasta 3.5, esta interpretación debe leerse sobre cantidades fraccionarias.

En comparación con el modelo simple, el múltiple incrementó R^2 en 0.1971, equivalente a 19.71 puntos porcentuales, y redujo el MAE en aproximadamente 21.4 %. En este conjunto de prueba, el modelo múltiple ofrece mejor ajuste y menor error medio. Esta comparación no demuestra que las variables causen el importe vendido.

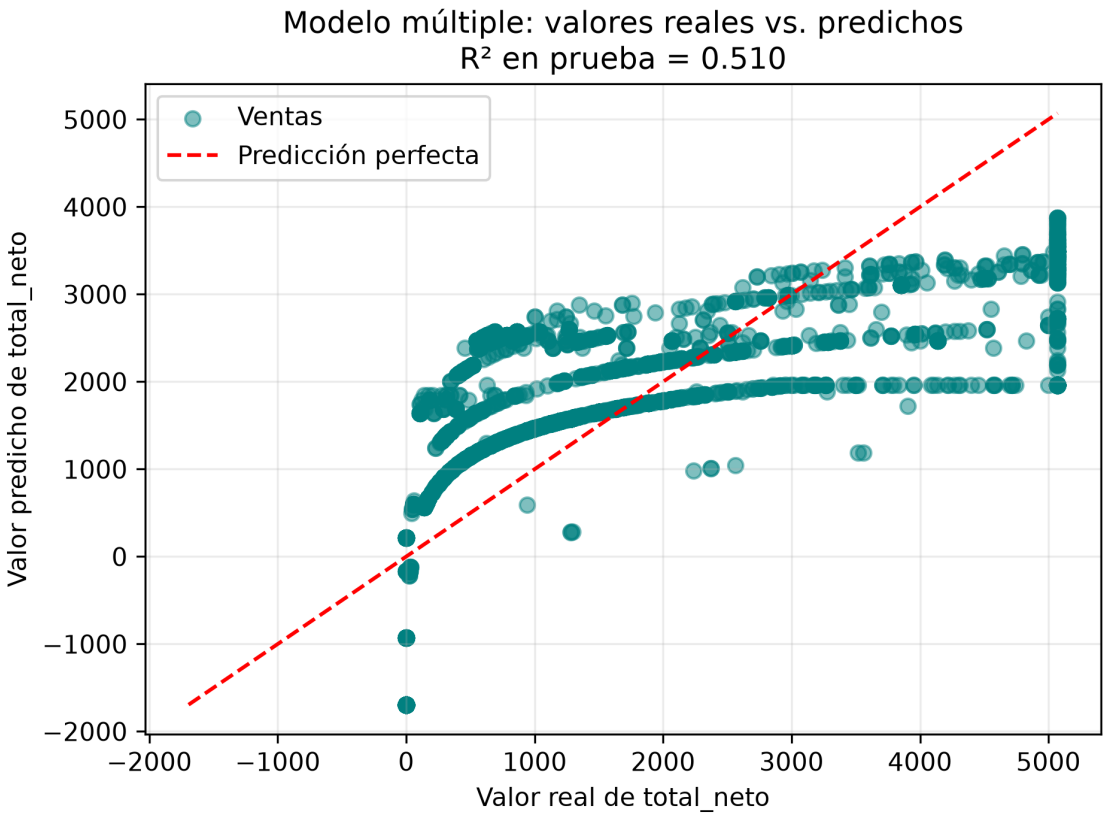


Figura 6: Valores reales frente a predichos por la regresión múltiple; la diagonal representa predicción perfecta.

5. Regresión logística

5.1. Construcción de la variable dicotómica

Se tomó `total_neto` y se convirtió en una respuesta binaria usando su mediana:

$$Y_{\text{binaria}} = \begin{cases} 1 & \text{si } \texttt{total_neto} \geq \$948{,}28 \quad \text{(venta alta)}, \\ 0 & \text{si } \texttt{total_neto} < \$948{,}28 \quad \text{(venta baja)}. \end{cases}$$

Así, la variable dicotómica es una clasificación de importe neto bajo/alto, no una columna binaria original del Excel. En los 21 632 registros, la clase 0 contiene 10 806 ventas y la clase 1 contiene 10 826. La distribución está casi equilibrada antes de entrenar.

5.2. Predictores y codificación

El modelo logístico incluyó los predictores numéricos `precio_unitario` transformado y `total_unidades`, más la columna categórica `marc`. La marca tenía 25 categorías. Se crearon

24 indicadores; la categoría de referencia omitida es `AG`. En total se ajustó el modelo con 26 predictores: dos numéricos y 24 indicadores de marca.

La regresión logística estima la probabilidad de clase 1 mediante la función:

$$P(Y = 1 \mid X) = \frac{1}{1 + \exp[-(\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p)]}.$$

El umbral de clasificación predeterminado del estimador es 0.5. Los coeficientes positivos aumentan los log-odds estimados de pertenecer a clase 1, y los negativos los disminuyen, siempre en comparación con la categoría de referencia para los indicadores de marca. No son efectos causales.

5.3. División y oversampling

El conjunto se dividió 80/20 con semilla 42 y estratificación por clase. El entrenamiento contenía 17 305 filas: 8 645 de clase 0 y 8 660 de clase 1. El oversampling manual tomó con reemplazo 15 filas de clase 0 y las agregó solamente al entrenamiento, dejando ambas clases con 8 660 ejemplos. No se duplicaron ejemplos del conjunto de prueba. La prueba conserva la distribución original del 20 %: 2 161 casos de clase 0 y 2 166 de clase 1.

Como el desbalance original era muy pequeño (20 registros en todo el conjunto), el oversampling solo añadió 15 ejemplos. Por ello, su influencia en el resultado global probablemente sea limitada.

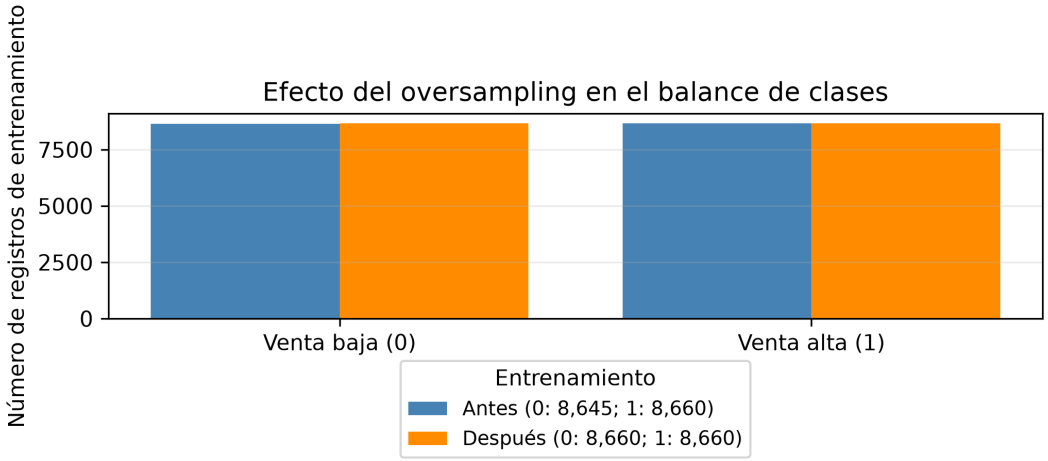


Figura 7: Comparación del número de casos por clase en el entrenamiento antes y después del oversampling.

5.4. Métricas por clase

La matriz de confusión usa filas para la clase real y columnas para la clase predicha. Sus conteos fueron:

Tabla 5: Matriz de confusión en el conjunto de prueba

	Predicha: venta baja (0)	**Predicha: venta alta (1)**
Real: venta baja (0)	2 033	128
Real: venta alta (1)	124	2 042

De las 2 161 ventas bajas reales, 2 033 se clasificaron correctamente como bajas y 128 se clasificaron como altas. De las 2 166 ventas altas reales, 2 042 se clasificaron correctamente como altas y 124 como bajas. La exactitud global fue 0.9418, o 94.18 %.

Tabla 6: Métricas detalladas por clase

Clase	**Precisión**	**Recall**	**F1**	**Soporte**
Venta baja (0)	0.9425	0.9408	0.9416	2 161
Venta alta (1)	0.9410	0.9428	0.9419	2 166
Promedio macro	0.9418	0.9418	0.9418	4 327
Promedio ponderado	0.9418	0.9418	0.9418	4 327

- **Precisión**: de todas las observaciones predichas como una clase, qué fracción realmente pertenece a esa clase. Para venta alta fue 0.9410.
- **Recall**: de todas las observaciones reales de una clase, qué fracción detectó el modelo. Para venta alta fue 0.9428; para venta baja fue 0.9408.
- **F1**: media armónica entre precisión y recall. Su valor cercano a 0.942 en las dos clases indica que ambas métricas están equilibradas.
- **Soporte**: cantidad de observaciones reales de cada clase evaluadas. No es una medida de calidad del modelo.

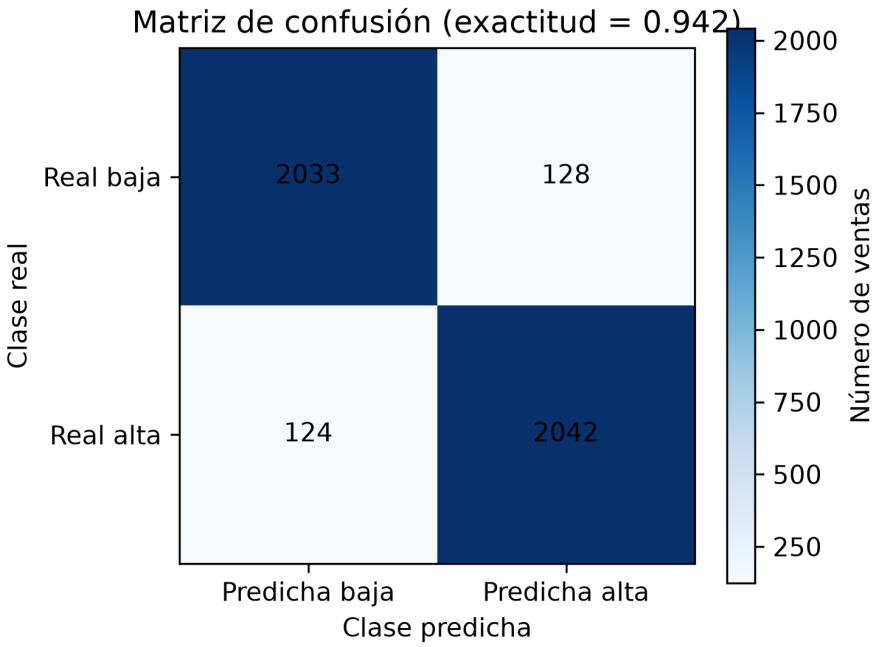


Figura 8: Matriz de confusión anotada con los cuatro conteos observados.

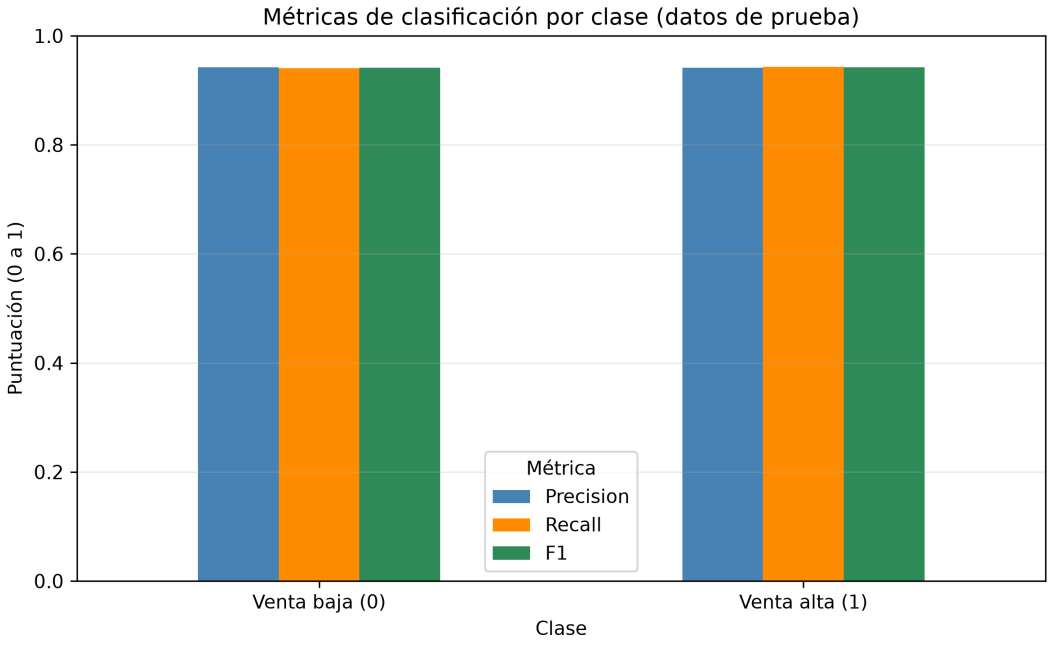


Figura 9: Comparación visual de precisión, recall y F1 para venta baja y venta alta.

6. Coeficientes logísticos

El modelo se ajustó con intercepto $-35{,}4185$. Los coeficientes de marca se interpretan respecto a la categoría de referencia `AG`, manteniendo constantes las demás variables:

Tabla 7: Coeficientes ajustados en la regresión logística

Variable	**Coeficiente**
Intercepto	-35.4185
`precio_unitario` transformado	4.8862
`total_unidades`	3.9786
Marca AIDITE	-2.0008
Marca ANAX DENT	-0.5129
Marca APPLE	-0.0234
Marca ARMA DENTAL	0.0008
Marca ASIGA	0.0542
Marca Actividad	0.0051
Marca CREATION	-2.8090
Marca CYBERPUERTA	0.0017
Marca DURRD	0.0030
Marca Dekem	-0.1282
Marca Denti	0.0072
Marca EXOCAD	0.0683
Marca HUGE	-0.7568
Marca IPD	2.7805
Marca JENSE	-0.2090
Marca Komet	-0.5038
Marca MEDIT	0.1926
Marca PHROZ	-1.2680
Marca QUATRO	0.0192
Marca RENFERT	0.0021
Marca ROKO	0.0109
Marca SCHIC	-0.0010
Marca Shining 3D	0.0007
Marca VITA	-3.1021

Los coeficientes numéricos son positivos, coherentes con que importes y cantidades mayores suelen asociarse con pertenecer a la clase de ventas altas. Los coeficientes de marca dependen

de la codificación y de la clase de referencia; no se deben interpretar aisladamente como una comparación comercial causal. Para interpretar magnitudes de forma más intuitiva se puede exponenciar un coeficiente para obtener un *odds ratio*, aunque la interpretación requiere mantener constantes los demás predictores.

7. Conclusiones

1. Los datos de ventas contenían 21 632 renglones y 492 nulos únicamente en código postal. La imputación numérica por mediana dejó cero faltantes.

2. Los extremos del precio, unidades y neto se limitaron con IQR. Los recortes conservaron las filas, pero redujeron el máximo de `total_neto` de \$2 170 948.28 a \$5 071.24.

3. La matriz original muestra una correlación precio–neto de 0.9927; después del preprocesamiento, el valor es 0.5577. Esta diferencia refleja sensibilidad a los valores extremos y a la transformación del precio.

4. La regresión múltiple rindió mejor que la simple en la prueba: $R^2 = 0{,}5102$ frente a 0,3131, con MAE de 870.258 frente a 1 107.417.

5. La clase dicotómica se definió con la mediana \$948.28. El modelo logístico obtuvo 94.18 % de exactitud y valores F1 de 0.9416 y 0.9419 para venta baja y alta, respectivamente.

6. Las métricas son similares entre las dos clases. El número de errores fue de 128 falsos positivos (venta baja clasificada como alta) y 124 falsos negativos (venta alta clasificada como baja).